

İST366 Regresyon Çözümleme Dersi

Dönem Ödevi

Miray İnci Başaran

22.05.2026

Table of Contents

1 - Senaryo.....	2
Bağımlı değişken (y).....	2
Bağımsız değişkenler.....	2
Kullanılan Kütüphaneler.....	2
2 - Tanımlayıcı İstatistikler	3
3 - Normallik İncelemesi ve Doğrusallık.....	4
Normallik Testi	4
Doğrusallık İncelemesi	8
Doğrusal Model	10
4 - Artık İncelemesi.....	11
5 - Son Veri Üzerinden Analizler	19
Son Veri Normallik Testi	19
Son Veri Doğrusallık İncelemesi	20
Son Veri İçin Artık İncelemesi	21
Son Veri Kestirim Denklemi	26
Model Anlamlılığı ve Kestirim Denklemi	28
6 - Katsayıların Anlamlılıkları.....	29
7 - Belirtme Katsayısı.....	30
8 - Güven Aralıkları	31
9 - Değişen Varyanslılık Sorunu	32
10 - Özilişki Sorunu İncelemesi	34
11 - Çoklu Bağlantı Sorunu İncelemesi	35
12 - Uyum Kestirimi	37
13 - Ön Kestirim	37
14 - Uyum Kestirimi ve Ön Kestirime Ait Güven Aralıkları	38

15 - Değişken Seçimi ile Model Kurma	39
16 - Ridge Regresyon	43

1 - Senaryo

Bu veri setindeki değerleri ve değişkenleri çimento sağlamlığını etkilemesi yönünden analiz edebiliriz.

Bağımlı değişken (y)

Çimento Sağlamlığı (mpa)

Bağımsız değişkenler

x1 = Su Miktarı (L)

x2 = İdeal_Kum_Miktarından_Sapma_(kg)

x3 = Karıştırma_Süresi_(dk)

x4 (nitel) = Çimento Türü (Portland, Beyaz Çimento, Katkılı Çimento)

Kullanılan Kütüphaneler

```
library(zoo)
library(nortest)
library(graphics)
library(lmtest)
library(olsrr)
library(MASS)
```

2 - Tanımlayıcı İstatistikler

```
data<-read.table("file 165_2230329044_MirayInciBasaran.txt",
                 header = TRUE)
names(data)<-c("y", "x1", "x2", "x3", "x4")
names(data)

## [1] "y"  "x1" "x2" "x3" "x4"

attach(data)

summary(data)
```

##	y	x1	x2	x3
##	Min. : -0.7432	Min. : 0.3849	Min. : 1.608	Min. : 2.938
##	1st Qu.: 28.8920	1st Qu.: 3.2771	1st Qu.: 4.238	1st Qu.: 5.130
##	Median : 37.8192	Median : 4.0239	Median : 4.868	Median : 5.839
##	Mean : 38.8799	Mean : 3.9878	Mean : 4.899	Mean : 5.882
##	3rd Qu.: 47.0075	3rd Qu.: 4.5878	3rd Qu.: 5.579	3rd Qu.: 6.499
##	Max. : 95.6745	Max. : 6.7984	Max. : 8.240	Max. : 8.868

##	x4
##	Min. : 1.000
##	1st Qu.: 1.000
##	Median : 2.000
##	Mean : 2.017
##	3rd Qu.: 3.000
##	Max. : 3.000

3 - Normallik İncelemesi ve Doğrusallık

Normallik Testi

Bağımlı değişkenin normal dağılıma uyup uymadığını görmek için %95 güven düzeyinde hipotez kurarız. ($p=0.05$)


H_0 : Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark yoktur.

H_S : Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark vardır.

```
#Normallik
```

```
qqnorm(y)
```

```
qqline(y)
```



```
lillie.test(y)
```

```
##
```


```
##  Lilliefors (Kolmogorov-Smirnov) normality test
```

```
##
```

```
## data:  y
```

```
## D = 0.07376, p-value = 0.004052
```

```
boxplot(y)
```



Kolmogorov-Smirnov testi ile verimizin normal dağılıma uyup uymadığına baktığımızda $p\text{-value}(0.004052) < 0.05$ olduğu için H_0 reddedilir. Veriler normal dağılıma uymaz. Bu yüzden “ln” dönüşümü uyguluyoruz. Hipotezleri tekrardan yazarız.

H_0 : Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark yoktur.


H_S : Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark vardır.

```
lny<-log(y)
```

```
## Warning in log(y): NaNs produced
```

```
qqnorm(lny)
```


```
qqline(lny)
```



```
lillie.test(lny)
```

```
##  
##  Lilliefors (Kolmogorov-Smirnov) normality test  
##  
## data:  ln y  
## D = 0.079227, p-value = 0.001379
```

```
boxplot(lny)
```



Test sonucuna baktığımız zaman p-value(0.001379) < 0.05 olduğu için H0 tekrar reddedilir. Verilerin normal dağılıma uymasında dönüşüm yapmak da etkili olmadığı için aykırı değer incelemesi yapılır ve o değerler veriden çıkarılır.

Bunun için verinin dönüşüm yapılmamış hali kullanılmıştır.


```
#Sağlamlığı 70'den küçük olanları tut.  
data_temiz <- subset(data, y < 70)  
data_temiz  
try(detach(data), silent = TRUE)  
attach(data_temiz)
```

Veri temizlendikten sonra tekrardan normallik testi yapılır.

H0: Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark yoktur.

HS: Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark vardır.

```
#Temiz veri üzerinden normallik testi  
qqnorm(y)  
qqline(y)
```




```
lillie.test(y)

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  y
## D = 0.030539, p-value = 0.8857
```

Elde edilen test sonucunda $p\text{-value}(0.8857) > 0.05$ olduğu için H_0 reddedilemez. Çimento sağlamlığı verilerinin normal dağılıma uyduğunu %95 güven düzeyinde söyleyebiliriz.

Doğrusallık İncelemesi

```
#Doğrusallık
pairs(data_temiz)
```



Çimento sağlamlığının diğer nicel bağımsız değişkenler ile arasındaki ilişkiye baktığımızda bu üç değişkenin de çimento sağlamlığı ile pozitif ve doğrusal bir eğilim gösterdiğini söyleyebiliriz.

Çimento sağlamlığının nitel değişken ile arasındaki ilişkiye baktığımızda ise dikey olarak görülen 3 sütun bize nitel değişkenin 3 durumu ifade ettiğini ve kendisinin kategorik bir değişken olduğunu gösterir.

Doğrusal Model

```
#Doğrusal model
sonuc<-lm(y~x1+x2+x3+factor(x4))
summary(sonuc)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + factor(x4))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.8282 -0.2887  0.0962  1.6274  3.5199
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   6.3708     1.0619   6.00 8.34e-09 ***
## x1            10.1288     0.2461  41.15 < 2e-16 ***
## x2             1.6412     0.2835   5.79 2.49e-08 ***
## x3            -1.9594     0.2268  -8.64 1.32e-15 ***
## factor(x4)2   -9.3359     0.4771 -19.57 < 2e-16 ***
## factor(x4)3   -9.3444     0.4774 -19.57 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.838 on 214 degrees of freedom
## Multiple R-squared:  0.9439, Adjusted R-squared:  0.9426
## F-statistic: 720.4 on 5 and 214 DF,  p-value: < 2.2e-16
```

Varsayımlar sağlandıktan sonra doğrusal modelimizi kurduk. Modelin p-değeri($2.2e-16$) <0.05 olduğu için model istatistiksel olarak anlamlıdır fakat modelin daha doğru sonuç vermesi için artık incelemesi yapmamız gerekir.

4 - Artık İncelemesi

```
#Artık İncelemesi
```

```
#standart -> [-2:2]
```

```
#student -> [-2:2]
```

```
#cook ->  $4/n = 4/220 = 0.0182$ 
```

```
#hat ->  $2*k/n = 2*6/220 = 0.0545$ 
```

```
inf<-ls.diag(sonuc)
```

```
inf
```

Artık incelemesi yaparken **4 farklı yöntem** kullanırız. Bu yöntemler aracılığıyla hangi değerlerin veriden çıkarılıp çıkarılmayacağını görmek için grafik çizeriz.


```
#Cook içi grafik
```

```
plot(inf$cooks, type = "p", pch = 8,  
     main = "Influential Obs by Cooks distance",  
     xlab = "Index", ylab = "cooks")
```

```
abline(h = 4/length(y), col = "red")
```

```
cooks_out <- which(inf$cooks > 4/length(y))
```


```
text(cooks_out, inf$cooks[cooks_out], labels = cooks_out, pos = 4, col = "red",  
     cex = 0.8)
```



Cook Uzaklığına baktığımızda bazı gözlemlerin etkin aykırı değer olduklarını görüyoruz. $n > 50$ olduğu için $4/n$ formülü kullanılır. $4/n = 4/220 = 0.0182$ değerinden büyük olanlar etkin gözlemlerdir.

#Hat için grafik

```
plot(inf$hat, type = "p", pch = 8,
     main = "Leverage Value by Hat value",
     xlab = "Index", ylab = "hat")
k <- length(sonuc$coefficients)
abline(h = 2*k/length(y), col = "red")
hat_out <- which(inf$hat > 2*k/length(y))
text(hat_out, inf$hat[hat_out], labels = hat_out, pos = 4, col = "red", cex =
0.8)
```




Gözlem Uzaklığı (hii) için grafik çizdirdiğimizde 62, 85, 86, 87, 101, 144, 146, 184, 196. değerlerin uç değer olduklarını görüyoruz. $26/n = 26/220 = 0.0545$ formülünü uyguladığımız zaman değerinden büyük olanları veriden çıkarmamız gerekir.

#Standart için grafik


```
plot(inf$std.res, type = "p", pch = 8,
     main = "Outlier by Standardized residuals",
     xlab = "Index", ylab = "Standardized Residuals")
```

```
abline(h = c(-2, 2), col = "red")
std_out <- which(abs(inf$std.res) > 2)
text(std_out, inf$std.res[std_out], labels = std_out, pos = 4, col = "red", cex = 0.8)
```



```
#Studentized için grafik
plot(inf$stud.res, type = "p", pch = 8,
      main = "Outlier by Studentized residuals",
      xlab = "Index", ylab = "Studentized Residuals")
abline(h = c(-2, 2), col = "red")
stud_out <- which(abs(inf$stud.res) > 2)
text(stud_out, inf$stud.res[stud_out], labels = stud_out, pos = 4, col = "red", cex = 0.8)
```

Outlier by Studentized residuals



Standartlaştırılmış ve student tipi artıklara baktığımız zaman $[-2, 2]$ aralığında kalmayanlar aykırı değerlerdir. Grafikte 55. ile 70. indeksler arasındaki gözlemlerin $[-2, 2]$ sınırlarının altında kaldığı görülmektedir. Bu gözlemler negatif yönde aykırı değerlerdir.

Artıkları Veriden Çıkarmak

En doğru modeli kurmak için artık değerlerimizi veriden çıkarıp bütün işlemleri tekrardan yaparız.

#Artıkları temizlemek

```
k<-length(sonuc$coefficients)
```

```
son_veri<-data_temiz[inf$cooks < (4/length(y)) &
                      inf$hat < (2*k/length(y)) &
                      abs(inf$stud.res) < 2 &
                      abs(inf$std.res) < 2, ]
```

```
son_veri
```

```
##          y          x1          x2          x3 x4
## 1  55.655110  5.060668  4.639999  6.274721  1
## 2  49.795956  4.441148  4.990986  6.219205  1
## 3  46.959365  3.980031  5.779795  5.977292  1
## 5  46.150891  3.947687  4.658691  5.373235  1
```

## 6	41.912723	3.541452	4.926841	5.605647	1
## 7	50.691612	4.578621	6.102225	7.231926	1
## 8	55.569928	4.880634	5.895548	6.371860	1
## 9	43.191251	3.866493	4.515699	6.158390	1
## 10	51.685531	4.661999	5.883222	7.022581	1
## 11	63.138315	5.619819	5.582045	6.318246	1
## 12	63.847128	5.729681	6.084628	6.849817	1
## 13	27.704648	2.577254	3.272206	6.360675	1
## 14	40.914132	3.519977	3.477910	4.895769	1
## 16	39.539560	3.258137	4.278926	4.933488	1
## 17	45.308053	4.132430	4.722263	6.565152	1
## 18	44.754495	4.066700	6.867459	8.099745	1
## 19	33.098608	2.538766	3.195710	3.848980	1
## 20	27.423206	2.201394	3.577159	5.140261	1
## 21	45.673021	3.770125	5.088211	5.121890	1
## 22	38.049390	3.227088	4.595368	5.661684	1
## 23	64.283540	5.659831	4.867180	5.574256	1
## 24	53.524263	4.386370	5.071665	4.513118	1
## 25	51.025504	4.442329	4.606730	5.452829	1
## 26	47.023546	3.919745	5.590919	5.556604	1
## 27	36.992950	3.652521	5.003572	8.252006	1
## 28	35.697993	2.844032	5.245800	5.549477	1
## 29	43.236375	4.006980	4.938836	7.053158	1
## 30	59.804372	5.019036	5.127515	4.736433	1
## 31	27.367802	2.184102	5.343234	6.497955	1
## 32	28.418649	2.447410	3.119617	5.385793	1
## 33	50.318214	4.427313	4.186680	5.393514	1
## 34	35.756827	3.247219	4.123374	6.373148	1
## 35	31.032073	2.542967	4.395438	5.639503	1
## 36	42.354082	3.494482	4.938942	5.231357	1
## 37	45.770563	4.023869	4.000474	5.398086	1
## 38	49.376088	4.023956	5.926814	5.264811	1
## 39	56.129370	4.982042	5.874340	6.570218	1
## 40	26.887026	2.180934	1.973194	4.078875	1
## 41	47.032365	4.055519	4.197031	5.149618	1
## 42	35.037469	2.726972	5.000709	5.157217	1
## 43	39.122707	3.240586	3.990159	4.825035	1
## 44	36.629880	3.114078	4.485660	5.705638	1
## 45	34.604485	3.028947	4.686344	6.365357	1
## 46	52.803758	4.689940	3.500025	5.070456	1
## 47	51.691600	4.274204	4.814125	4.603204	1
## 49	47.082402	4.011200	4.711185	5.296115	1
## 50	41.089172	3.264327	4.818646	4.707426	1
## 51	37.621107	3.323374	4.303005	6.034802	1
## 52	40.901064	3.801105	5.033059	7.226902	1
## 53	47.916323	4.294054	4.435216	5.975020	1
## 54	53.182323	4.420585	6.421230	5.735561	1
## 55	34.620059	2.733304	3.091698	3.942918	1
## 56	35.669042	3.091163	5.065985	6.460670	1
## 57	47.780590	4.241882	4.868242	6.107713	1

## 76	12.159273	1.811627	2.600235	4.180927	2
## 77	21.318100	2.663053	3.106918	4.202605	2
## 78	47.297615	5.327915	5.084134	6.260108	2
## 79	22.626454	2.808355	4.400793	5.212069	2
## 80	47.326413	5.099434	6.209357	6.000047	2
## 81	34.314716	4.043978	4.236863	5.422910	2
## 82	29.382114	3.735690	4.161822	6.103491	2
## 83	47.526375	5.105353	6.680728	6.267940	2
## 84	28.174808	3.354197	4.354973	5.126655	2
## 85	28.284102	3.314425	4.139616	4.759211	2
## 86	53.206800	5.838245	4.343051	5.667168	2
## 87	26.927715	3.314014	3.173310	4.635987	2
## 88	25.041399	3.023920	4.968979	5.516232	2
## 89	33.816783	4.259384	5.924451	7.775704	2
## 93	42.426683	4.649061	5.167393	5.336193	2
## 94	39.390869	4.418922	6.024976	6.189196	2
## 95	17.345205	2.268713	3.450253	4.500454	2
## 96	43.021788	4.623108	4.633778	4.628025	2
## 97	18.715725	2.646802	4.523932	6.311350	2
## 98	23.580198	3.146286	4.939839	6.636240	2
## 99	44.835029	5.214255	7.439520	8.406828	2
## 100	50.185118	5.367533	6.206662	6.006588	2
## 101	36.771602	3.972511	4.869990	4.550495	2
## 102	26.220734	3.457427	3.598575	5.839203	2
## 103	39.939522	5.049263	4.625279	7.751546	2
## 104	28.634349	3.668759	4.847911	6.632298	2
## 105	16.143841	2.106279	4.296761	5.001756	2
## 107	51.888404	5.550681	5.873895	5.900817	2
## 108	36.140230	4.099984	6.229374	6.323691	2
## 109	35.209356	4.014330	4.676379	5.232809	2
## 110	46.489552	5.248875	6.438682	7.159513	2
## 111	23.658437	2.771595	4.821995	4.942255	2
## 112	46.239656	5.099251	5.464181	5.938733	2
## 113	31.200620	3.547540	4.843132	5.032726	2
## 114	35.430145	3.876708	4.287151	4.292138	2
## 115	27.091318	3.407323	4.665535	6.035505	2
## 116	37.801986	4.022405	5.922337	5.079298	2
## 117	38.243028	4.375121	4.899668	5.685038	2
## 118	49.049944	5.703997	5.325931	7.376709	2
## 119	53.584347	5.947463	7.058794	7.766492	2
## 120	30.010173	3.605713	3.693752	4.956110	2
## 121	31.815260	3.664812	3.746056	4.501110	2
## 122	41.753785	4.581268	4.844111	5.099792	2
## 123	38.056044	4.668811	5.776075	7.662134	2
## 124	21.819572	2.967119	3.548036	5.582976	2
## 125	36.153344	4.027558	4.853825	5.024741	2
## 126	37.303542	4.310861	5.612780	6.298494	2
## 127	31.311995	3.928701	4.828744	6.601604	2
## 128	32.141983	3.997941	4.532409	6.337580	2
## 129	24.136202	2.953556	4.277336	5.086039	2

##	130	22.551267	2.833726	4.242767	5.230466	2
##	131	44.826245	4.793060	5.090973	4.933644	2
##	132	31.826701	4.003618	3.749599	5.943240	2
##	133	37.838019	4.365727	4.762290	5.716560	2
##	134	35.420898	4.238150	4.958985	6.305676	2
##	135	30.717745	3.878614	5.358550	7.026076	2
##	136	32.961266	4.107996	6.372002	7.815639	2
##	137	38.834529	4.494693	4.891919	5.952928	2
##	138	40.798442	4.590001	4.542870	5.323565	2
##	139	23.274158	3.104617	4.464670	6.229316	2
##	140	39.567828	4.539040	5.420670	6.209140	2
##	141	37.875931	4.195573	4.966593	5.111984	2
##	142	52.443870	5.644936	5.719607	5.991378	2
##	143	42.220261	4.879432	4.356850	5.878232	2
##	144	43.250958	4.807200	6.455663	6.575128	2
##	145	23.872170	2.703521	5.112188	4.793213	2
##	146	20.277798	2.904882	3.743033	6.125580	2
##	147	48.146534	5.700920	6.984971	8.868337	2
##	148	27.192146	3.384903	3.384797	4.972693	2
##	150	33.319777	4.033517	5.733760	6.864910	2
##	153	23.871629	2.979245	4.550108	5.509682	3
##	154	34.451833	4.070814	5.134548	6.113374	3
##	155	34.207636	4.037804	3.964943	5.253499	3
##	156	9.183109	1.535556	3.267111	4.855071	3
##	157	39.111052	3.966454	5.846025	4.254899	3
##	158	14.095073	1.879170	3.935362	4.669221	3
##	159	40.393795	4.651236	4.888920	5.988362	3
##	160	46.409708	5.362810	5.495718	7.052667	3
##	161	25.640383	3.073603	6.116217	6.349793	3
##	162	37.931274	4.226406	4.201424	4.699934	3
##	163	31.487272	3.877690	4.164483	5.832572	3
##	164	26.272436	3.271583	5.163268	6.181073	3
##	165	28.185294	3.528978	4.674153	6.096077	3
##	166	57.188234	6.311246	7.314288	8.096529	3
##	167	16.533144	2.369021	3.417100	5.235707	3
##	168	36.614103	4.230383	5.982558	6.505828	3
##	170	52.947577	5.981654	6.261596	7.645731	3
##	171	19.432000	2.871678	3.319917	6.031032	3
##	172	30.984218	3.632437	5.557714	6.005172	3
##	173	52.049065	5.649945	5.101024	5.773038	3
##	174	31.893035	3.932053	5.274241	6.694616	3
##	175	38.040731	4.101817	4.226452	4.145403	3
##	176	32.960122	4.027870	4.215236	5.900192	3
##	177	48.539844	5.380348	6.188417	6.723027	3
##	178	38.044180	4.124058	6.151549	5.574901	3
##	180	28.857725	3.537707	5.515265	6.473247	3
##	181	47.821436	5.225075	4.342697	5.118692	3
##	182	25.242011	3.536585	4.177807	7.019962	3
##	183	33.411648	4.085044	3.262548	5.307549	3
##	184	33.254166	3.823065	6.515724	6.570787	3

```

## 185 37.998984 4.478888 4.321333 5.838364 3
## 186 36.631601 4.368788 4.804961 6.259112 3
## 187 37.408241 4.536153 6.001103 7.515045 3
## 188 53.925624 5.907113 6.593369 7.131974 3
## 189 31.571986 3.729306 4.589698 5.464971 3
## 190 26.968103 3.398692 5.477776 6.661521 3
## 191 41.803721 4.556637 4.842020 4.972385 3
## 193 11.144632 1.800815 3.157951 5.006029 3
## 194 25.077474 3.215025 3.967299 5.558191 3
## 195 36.624198 4.391495 4.552367 6.185226 3
## 196 37.836318 4.493447 5.434317 6.741813 3
## 197 37.657745 4.296562 4.539102 5.339625 3
## 198 35.007697 4.258989 3.796546 5.761265 3
## 199 29.917716 3.812498 6.114326 7.650859 3
## 200 29.341619 3.655656 5.675770 6.891518 3
## 202 28.994916 3.195323 3.953002 3.841613 3
## 203 9.267297 1.414567 2.112513 3.420718 3
## 204 29.578968 3.416706 4.884397 5.188225 3
## 206 23.299100 3.097844 3.747721 5.654319 3
## 207 55.473216 6.232367 6.680256 8.019761 3
## 208 45.186839 5.092154 5.521021 6.376546 3
## 209 43.204369 4.673279 6.515943 6.055219 3
## 211 55.222734 5.664592 6.312280 5.347625 3
## 212 23.036063 3.125657 5.213646 6.995202 3
## 213 27.586577 3.392329 3.841069 5.163097 3
## 214 36.701160 4.554163 5.213896 7.328445 3
## 215 27.191158 3.829642 5.936643 8.775639 3
## 216 34.483605 3.984457 4.675014 5.403975 3
## 217 23.601729 3.060284 3.892837 5.474304 3
## 218 16.916962 2.422353 3.496621 5.353962 3
## 219 38.183723 4.085204 4.884516 4.462038 3
## 220 41.360349 4.885445 6.236019 7.552827 3
## 221 51.995560 5.643231 7.060965 7.062863 3
## 222 27.063628 3.702902 4.570753 7.247721 3
## 223 35.527974 4.212890 4.101073 5.555180 3
## 224 45.527864 4.805436 5.111725 4.718534 3
## 225 49.686132 5.578349 7.005240 7.689766 3
## 226 24.911458 3.159059 5.312770 6.402252 3
## 227 56.717148 6.263367 7.431379 8.152463 3
## 228 40.101469 4.618391 6.431047 7.049321 3
## 229 30.544267 3.748961 4.690630 6.052060 3
## 230 24.318728 3.083494 4.311857 5.579076 3

```

```
nrow(son_veri)
```

```
## [1] 196
```

5 - Son Veri Üzerinden Analizler

Son Veri Normallik Testi

Düzenlenmiş veri üzerinden bağımlı değişkenin normal dağılıma uyup uymadığını görmek için %95 güven düzeyinde tekrardan hipotez kurarız. ($p=0.05$)


H0: Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark yoktur.

HS: Çimento sağlamlığı verilerinin dağılımı ile normal dağılım arasında fark vardır.

```
#Normallik
```

```
qqnorm(y)
```

```
qqline(y)
```



```
lillie.test(y)
```

```
##
```


```
##  Lilliefors (Kolmogorov-Smirnov) normality test
```

```
##
```

```
## data:  y
```

```
## D = 0.030539, p-value = 0.8857
```


```
boxplot(y)
```



Yorum: K-S testi ile normallik incelemesi yaptığımızda p-value(0.8857) > 0.05 olduğu için H0 reddedilemez sonucuna ulaşırız. Çimento sağlamlığı verilerinin normal dağılıma uyduğunu %95 güven düzeyinde söyleyebiliriz.

Son Veri Doğrusallık İncelemesi

```
#Doğrusallık  
pairs(son_veri)
```



Yorum: Çimento sağlamlığı (y) ile sayısal bağımsız değişkenler (x1, x2, x3) arasındaki ilişkiye baktığımızda pozitif yönlü ve doğrusal bir eğilim gözlemlenmektedir. Bu ilişki özellikle x1 için en güçlü görünmektedir. Nitel değişken x4 ile bağımlı değişken arasındaki grafikte 3 sütunlu bir yapı görülmesinin sebebi, x4'ün 3 aşamalı kategorik bir değişken olmasından kaynaklanmaktadır.

Son Veri İçin Artık İncelemesi

#Yeni model

```
try(detach(data_temiz), silent = TRUE)
attach(son_veri)
```

```
son_model <- lm(y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
```

#Son model için tanımlar.

```
inf_son <- ls.diag(son_model)
```

```
p_son <- length(son_model$coefficients)
```

```
summary(son_model)
```

```
##
```

```
## Call:
```


```
## lm(formula = y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.21378 -0.14149 -0.08738  0.06790  0.75559
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.63251    0.09141  116.32  <2e-16 ***
## x1           10.28197    0.02028  507.11  <2e-16 ***
## x2            1.69671    0.02320   73.15  <2e-16 ***
## x3           -2.38446    0.01962 -121.51  <2e-16 ***
## factor(x4)2 -11.99832    0.03792 -316.44  <2e-16 ***
## factor(x4)3 -11.96017    0.03780 -316.37  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2083 on 190 degrees of freedom
## Multiple R-squared:  0.9997, Adjusted R-squared:  0.9997
## F-statistic: 1.124e+05 on 5 and 190 DF,  p-value: < 2.2e-16

#Cook içi grafik
plot(inf_son$cooks, type = "p", pch = 8,
     main = "Final: Influential Obs by Cooks distance",
     xlab = "Index", ylab = "cooks_d")
abline(h = 4/length(y), col = "red")

cooks_out <- which(inf_son$cooks > 4/length(y))
if(length(cooks_out) > 0) text(cooks_out, inf_son$cooks[cooks_out], labels =
cooks_out, pos = 4, col = "red", cex = 0.8)
```


Final: Influential Obs by Cooks distance



```
#Hat için grafik
plot(inf_son$hat, type = "p", pch = 8,
     main = "Final: Leverage Value by Hat value",
     xlab = "Index", ylab = "hat")
abline(h = 2*p_son/length(y), col = "red")

hat_out <- which(inf_son$hat > 2*p_son/length(y))
if(length(hat_out) > 0) text(hat_out, inf_son$hat[hat_out], labels = hat_out,
pos = 4, col = "red", cex = 0.8)
```

Final: Leverage Value by Hat value




```
#Standart için grafik
plot(inf_son$std.res, type = "p", pch = 8,
     main = "Final: Outlier by Standardized residuals",
     xlab = "Index", ylab = "Standardized Residuals")
abline(h = c(-2, 2), col = "red")

std_out <- which(abs(inf_son$std.res) > 2)
if(length(std_out) > 0) {
  text(std_out, inf_son$std.res[std_out], labels = std_out, pos = 4, col = "red",
       cex = 0.8)}

```


Final: Outlier by Standardized residuals



```
#Studentized için grafik
plot(inf_son$stud.res, type = "p", pch = 8,
     main = "Final: Outlier by Studentized residuals",
     xlab = "Index", ylab = "Studentized Residuals")
abline(h = c(-2, 2), col = "red")

stud_out <- which(abs(inf_son$stud.res) > 2)
if(length(stud_out) > 0) {
  text(stud_out, inf_son$stud.res[stud_out], labels = stud_out, pos = 4, col
= "red", cex = 0.8)
}
```

Final: Outlier by Studentized residuals



Son Veri Kestirim Denklemi

Varsayımlar sağlandığı için model kestirim denklemini kurabiliriz.

```
summary(son_model)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.21378 -0.14149 -0.08738  0.06790  0.75559
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.63251    0.09141  116.32  <2e-16 ***
## x1           10.28197    0.02028   507.11  <2e-16 ***
## x2            1.69671    0.02320    73.15  <2e-16 ***
## x3           -2.38446    0.01962  -121.51  <2e-16 ***
## factor(x4)2 -11.99832    0.03792  -316.44  <2e-16 ***
## factor(x4)3 -11.96017    0.03780  -316.37  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##  
## Residual standard error: 0.2083 on 190 degrees of freedom  
## Multiple R-squared:  0.9997, Adjusted R-squared:  0.9997  
## F-statistic: 1.124e+05 on 5 and 190 DF,  p-value: < 2.2e-16
```

Model Anlamlılığı ve Kestirim Denklemi

Modelin anlamlılığına bakarken çıktının sonundaki p-value değeri kullanılır.

H0: Model anlamsızdır. HS: Model anlamlıdır.

p-value(2.2e-16) < 0.05 olduğu için H0 reddedilir. Model %95 güven düzeyinde anlamlıdır.

$$\hat{y} = \underset{(0.0914)}{10.6325} + \underset{(0.0203)}{10.2820}X_1 + \underset{(0.0232)}{1.6967}X_2 - \underset{(0.0196)}{2.3845}X_3 - \underset{(0.0379)}{11.9983}D_2 - \underset{(0.0378)}{11.9602}D_3 \pm 0.2083$$

Not: Modelde nitel değişken varsa nitel değişken içerisinde 1 durumu kılavuz değişken olarak almak gerekir. Burada Portland türü çimentoyu kılavuz değişken olarak aldığımız için modelde gözükmez. Hipotez kurarken bu duruma dikkat edilmelidir.

6 - Katsayıların Anlamlılıkları

Model denklemi oluşturduktan sonra bakmamız gereken bir diğer konu modele giren değişkenlerin anlamlılığıdır. Her biri için hipotez yazılıp (H_0 : Anlamsızdır) test edilir. Anlamsız bulunan değişkenler modele dahil edilmezler.

$$\begin{aligned} H_0 &: \beta_1 = 0 \\ H_1 &: \beta_1 \neq 0 \end{aligned}$$

Yorum: Diğer değişkenler sabit tutulduğunda çimento sağlamlığı bakımından su miktarındaki (x_1) değişimin anlamlı olduğunu %95 güven düzeyinde söyleyebiliriz [p-value($2e-16$) < 0.05]. Su miktarındaki 1 birim artışta çimento sağlamlığı ortalama 10.28 mpa(megapaskal) artar.

$$\begin{aligned} H_0 &: \beta_2 = 0 \\ H_1 &: \beta_2 \neq 0 \end{aligned}$$

Yorum: Diğer değişkenler sabit tutulduğunda çimento sağlamlığı bakımından ideal kum miktarından sapmanın (x_2) anlamlı olduğunu %95 güven düzeyinde söyleyebiliriz [p-value($<2e-16$) < 0.05]. Sapmadaki 1 birimlik artışta çimento sağlamlığı ortalama 1.70 mpa(megapaskal) artar. (Yeni veri setimizde x_2 değişkeni anlamlı olmasına rağmen, orijinal proje adımlarına sadık kalmak ve model karşılaştırması yapmak adına x_2 'nin modelden çıkarıldığı son_model_v2 modelini de kurup karşılaştırmaktayız).

$$\begin{aligned} H_0 &: \beta_3 = 0 \\ H_1 &: \beta_3 \neq 0 \end{aligned}$$

Yorum: Diğer değişkenler sabit tutulduğunda çimento sağlamlığı bakımından karıştırma süresindeki (x_3) değişimin anlamlı olduğunu %95 güven düzeyinde söyleyebiliriz [p-value($2e-16$) < 0.05]. Karıştırma süresindeki (dk) 1 birim artışta çimento sağlamlığı ortalama 2.38 mpa(megapaskal) azalır.

$$\begin{aligned} H_0 &: \beta_4 = 0 \text{ (Portland tipi çimento ile Beyaz çimento arasında fark yoktur.)} \\ H_1 &: \beta_4 \neq 0 \text{ (Portland tipi çimento ile Beyaz çimento arasında fark vardır.)} \end{aligned}$$

Yorum: Çimento sağlamlığı bakımından Portland tipi çimento ile Beyaz çimento arasında istatistiksel olarak anlamlı bir fark olduğunu %95 güven düzeyinde söyleyebiliriz [p-value($2e-16$) < 0.05]. Portland tipi çimento Beyaz çimentoya göre sağlamlık açısından daha iyidir (yaklaşık 12.00 mpa daha sağlamdır).

$$\begin{aligned} H_0 &: \beta_4 = 0 \text{ (Portland tipi çimento ile Katkılı çimento arasında fark yoktur.)} \\ H_1 &: \beta_4 \neq 0 \text{ (Portland tipi çimento ile Katkılı çimento arasında fark vardır.)} \end{aligned}$$

Yorum: Çimento sağlamlığı bakımından Portland tipi çimento ile Katkılı çimento arasında istatistiksel olarak anlamlı bir fark olduğunu %95 güven düzeyinde söyleyebiliriz [p-value($2e-16$) < 0.05]. Portland tipi çimento Katkılı çimentoya göre sağlamlık açısından daha iyidir (yaklaşık 11.96 mpa daha sağlamdır).

x2 deęiřkeni anlamlı olduęundan ve deęiřken seęimi yntemlerinin tamamı x2'yi modelde tuttuęundan, 12. maddeden itibaren yapılan tm analizlerde son_model ($x_1+x_2+x_3+x_4$) esas alınmıřtır. son_model_v2 yalnızca karřılařtırma amaęlı sunulmuřtur.

7 - Belirtme Katsayısı

Yeni veri setimizde kurduęumuz son modelin (son_model) Dzeltmiř Belirtme Katsayısı 0.9997 olarak hesaplanmıřtır. Bu deęer, imento saęlamlıęındaki deęiřimin %99.97'sinin modeldeki baęımsız deęiřkenler tarafından aıklandıęını gstermektedir. Orijinal adımları takip ederek x2 deęiřkenini ıkardıęımız modelde (son_model_v2) ise Dzeltmiř Belirtme Katsayısı 0.9899 (%98.99) olarak elde edilmiřtir.

8 - Güven Aralıkları

```
confint(son_model, level = .99)
```

```
##              0.5 %      99.5 %  
## (Intercept) 10.394667 10.870352  
## x1          10.229216 10.334728  
## x2          1.636356 1.757065  
## x3          -2.435515 -2.333395  
## factor(x4)2 -12.096982 -11.899668  
## factor(x4)3 -12.058539 -11.861808
```

Not: Bu aralıklar, ilgili değişkenin 1 birimlik artışta çimento sağlamlığını ortalama ne kadar değiştirdiğini %99 güvenle gösterir. Eğer aralık 0 değerini içerirse ilgili değişkenin anlamsız olduğunu söyleyebiliriz.

Yorum 1 - Su Miktarı: Güven aralığının sadece pozitif değerlerden oluşması (0'ı içermemesi) su miktarının anlamlı bir değişken olduğunu gösterir. Ayrıca su miktarındaki 1 birim artışın çimento sağlamlığını %99 güvenle ortalama [10.229:10.335] aralığı kadar arttırabileceğini söyleyebiliriz.

Yorum 2 - İdeal Kum Miktarından Sapma: Bu yeni veri setinde güven aralığı sadece pozitif değerlerden oluşmaktadır [1.636:1.757] ve 0'ı içermemektedir. Bu durum, x2 değişkeninin modele katkısının bu veri setinde anlamlı olduğunu gösterir. İdeal kum miktarından sapmadaki 1 birimlik artışın sağlamlığı ortalama [1.636:1.757] mpa arttırabileceğini %99 güvenle söyleyebiliriz.

Yorum 3 - Karıştırma Süresi: Bu değişkenin güven aralığı sadece negatif değerlerden oluşuyor [-2.436:-2.333]. Bu ayrıca bağımlı değişkenle aralarında negatif yönlü bir ilişki olduğunu gösterir. Karıştırma süresindeki 1 birim artışın çimento sağlamlığında %99 güvenle ortalama [-2.436:-2.333] kadar bir düşüşe yol açacağı söylenebilir.


Yorum 4 - Çimento Türleri: Çimento türleri nitel değişken oldukları için aralarından biri kılavuz değişken olarak seçilmişti. Bu yüzden karşılaştırma kılavuz değişkene göre yapılır. İki güven aralığı da negatif değerleri içerir ([-12.097:-11.899], [-12.059:-11.862]) bu iki çimento türünün kılavuz seçilen Portland türü çimento ile aralarındaki farkın anlamlı olduğunu (aralıklar 0'ı içermiyor) ve iki türün de Portland türü çimentodan sağlamlık açısından daha kötü olduğunu %99 güvenle söyleyebiliriz.

9 - Değişen Varyanslık Sorunu

Tanım: Değişken varyanslık, denklem varsayımlarından $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_n^2 = \sigma^2$ varsayımının bozulmasıdır. Bu varsayım bozulmasını Breusch-Pagan (BP) Testi ile test etmemiz gerekir.

```
# Grafik için alanı hazırla
par(mfrow=c(1,1))

# Tahmin edilen değerler vs. Studentized Artıklar
plot(predict(son_model), rstudent(son_model),
     main="Değişen Varyanslılık Kontrolü",
     xlab="Tahmin Edilen Değerler",
     ylab="Studentized Artıklar")
abline(h=0, col="red")
```



Yorum: Grafiği incelediğimizde artıkların referans çizgisi ($h=0$) etrafında rastgele dağıldığını söyleyebiliriz. Ayrıca değerlerin daha çok $[-2;2]$ aralığında dağılması olası aykırı değerlerin az olduğunu gösterir.

```
# Breusch-Pagan Testi
bptest(son_model)
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: son_model  
## BP = 5.0183, df = 5, p-value = 0.4137
```

H_0 : Varyanslar homojendir.

H_1 : Varyanslar homojen değildir.

Yorum: Breusch-Pagan testi sonucuna baktığımızda elde ettiğimiz p-value(0.4137)>0.05 olduğu için H_0 hipotezimiz reddedilemez sonucuna ulaşırız. Böylelikle varyansların homojen olduğunu %95 güven düzeyinde söyleyebiliriz.

10 - Özilişki Sorunu İncelemesi

Tanım: Tanım: Model varsayımlarından biri de yanılğı terimlerinin ilişkili olmaması varsayımı idi. Bu varsayımın bozulması, böylece, i'inci ve j'inci gözlemlere karşılık gelen yanılğı terimlerinin bağımsız olmaması ilişkili yanılğı sorununu ortaya çıkartır. Eğer bu ilişki, gözlemlerin zaman gibi doğal bir sırada olduğu verilerde ortaya çıkmışsa dizisel ilişki ya da özilişki (otokorelasyon) adını alır.

```
dwtest(son_model)
```

```
##  
## Durbin-Watson test  
##  
## data: son_model  
## DW = 2.0603, p-value = 0.6113  
## alternative hypothesis: true autocorrelation is greater than 0
```

Yorum: Durbin Watson testine göre test değeri $d=2.0603$ bulunmuştur. Bu değeri 2'ye oldukça yakındır. p-değeri incelendiğinde $p\text{-value}(0.6113) > 0.05$ olduğu için H_0 hipotezimiz reddedilemez sonucuna ulaşırız. Bu durum, modelimizde özilişki (otokorelasyon) sorunu olmadığını %95 güven düzeyinde gösterir. Orijinal raporda özilişki sorunu çıkmışken, bu veri setinde varsayım tam olarak sağlanmıştır.

H_0 : Özilişki yoktur.

H_1 : Pozitif yönlü özilişki vardır.

11 - Çoklu Bağlantı Sorunu İncelemesi

```
ols_coll_diag(son_model)
```

```
## Tolerance and Variance Inflation Factor
## -----
##      Variables Tolerance      VIF
## 1          x1 0.5481590 1.824288
## 2          x2 0.3911115 2.556815
## 3          x3 0.5461825 1.830890
## 4 factor(x4)2 0.6705338 1.491349
## 5 factor(x4)3 0.6663551 1.500701
##
##
## Eigenvalue and Condition Index
## -----
##      Eigenvalue Condition Index      intercept          x1          x2
## 1 4.711045365      1.000000 1.163564e-03 1.395374e-03 7.218177e-04
## 2 1.000155491      2.170326 7.400109e-07 1.373038e-06 1.425369e-07
## 3 0.229734910      4.528404 3.567909e-03 6.810844e-03 3.539544e-03
## 4 0.032030783     12.127600 2.955789e-01 5.265071e-01 1.166869e-02
## 5 0.017307375     16.498446 5.162032e-01 3.232397e-01 2.919180e-01
## 6 0.009726076     22.008468 1.834857e-01 1.420457e-01 6.921519e-01
##
##      x3 factor(x4)2 factor(x4)3
## 1 7.049773e-04 0.0076583972 0.0078960815
## 2 1.257281e-06 0.2211639526 0.2051423219
## 3 3.031094e-03 0.7549920549 0.7789740007
## 4 4.568051e-02 0.0039659676 0.0070398746
## 5 1.649662e-01 0.0113592542 0.0008406637
## 6 7.856159e-01 0.0008603734 0.0001070575
```

VIF Yorumu: Bağımsız değişkenlerimize karşılık gelen VIF değerleri incelendiğinde ($x_1=1.82$, $x_2=2.56$, $x_3=1.83$) tüm değerlerin 10'dan küçük olduğu görülmektedir. Bu durum, modelimizde çoklu bağlantı sorunu bulunmadığını gösterir.

Tolerans Yorumu: Değişkenlerin tolerans değerleri sıfıra yakın olmayıp (en düşük tolerans x_2 için 0.39), kabul edilebilir sınırlar içerisinde. Çoklu bağlantıdan şüphelenilmez.

Koşul Sayısı ve Varyans Bozulmuş Oranları Yorumu: Koşul sayıları incelendiğinde en büyük koşul sayısı 22.01'dir. Bu değer 30'dan küçük olduğu için güçlü bir çoklu bağlantı yapısı bulunmamaktadır.

Özdeğer Yorumu: Özdeğerlerin tersleri toplamı k bağımsız değişken sayısından çok çok büyükse güçlü çoklu bağlantı vardır.

```
ozdeger = 1/4.711045365 + 1/1.000155491 + 1/0.229734910 + 1/0.032030783 + 1/0.017307375 + 1/0.009726076
```

```
ozdeger
```

```
## [1] 197.3801
```

Özdeğer Sonuç Yorumu: Özdeğerlerin terslerinin toplamı yaklaşık 197.38 olarak bulunmuştur. Bu değer orijinal veriye kıyasla oldukça düşüktür ve modelde ciddi bir çoklu bağlantı sorunu olmadığını doğrulamaktadır.

Yeni Model

Son model üzerinden yaptığımız anlamlılık ve çoklu bağlantı incelemelerinden sonra x2 değişkenini modelden çıkaralım.

```
# Yeni ve güncel model
```

```
son_model_v2 <- lm(y ~ x1 + x3 + factor(x4), data = son_veri)
```

```
summary(son_model_v2)
```

```
##
```

```
## Call:
```

```
## lm(formula = y ~ x1 + x3 + factor(x4), data = son_veri)
```

```
##
```

```
## Residuals:
```

```
##      Min       1Q   Median       3Q      Max
```

```
## -2.72260 -0.76928 -0.00261  0.71873  2.74413
```

```
##
```

```
## Coefficients:
```

```
##              Estimate Std. Error t value Pr(>|t|)
```

```
## (Intercept)  11.20803     0.49049   22.85  <2e-16 ***
```

```
## x1           11.07756     0.09216  120.20  <2e-16 ***
```

```
## x3          -1.61356     0.08916  -18.10  <2e-16 ***
```

```
## factor(x4)2 -11.97187     0.20420  -58.63  <2e-16 ***
```

```
## factor(x4)3 -11.91423     0.20358  -58.52  <2e-16 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
```

```
## Residual standard error: 1.122 on 191 degrees of freedom
```

```
## Multiple R-squared:  0.9901, Adjusted R-squared:  0.9899
```

```
## F-statistic: 4796 on 4 and 191 DF, p-value: < 2.2e-16
```

$$\hat{y} = 11.2080 + 11.0776X_1 - 1.6136X_3 - 11.9719D_2 - 11.9142D_3 \pm 1.1220$$

(0.4905) (0.0922) (0.0892) (0.2042) (0.2036)

Bu yeni veri setinde x2 değişkeni anlamlı çıkmış ve çoklu bağlantıya yol açmamış olsa da, orijinal ödev formatına ve karşılaştırma bütünlüğüne sadık kalmak adına, x2 değişkenini çıkartarak son_model_v2 modelini kurduk. Bu modelde de bütün değişkenler anlamlıdır ve belirtme katsayısı %98.99'dur. İlerleyen adımlara bu model (son_model_v2) üzerinden devam edilmiştir.

12 - Uyum Kestirimi

```
uyum_kestirimi <- son_veri[41, ]  
  
uyum_kestirimi_deger <- predict(son_model_v2, newdata = uyum_kestirimi)  
  
uyum_kestirimi_deger  
  
##          43  
## 39.32035
```

Tahmin edilen $\hat{y} = 39.32035$

Yorum: Model kullanılarak veri kümesi içindeki 43 numaralı gözlem (temiz veri setinin 41. satırı) için yapılan uyum kestirimi sonucunda 39.32035 mpa değeri elde edilmiştir. Bu değer, bağımsız değişkenlerin mevcut seviyeleri altında modelin öngördüğü sağlamlık miktarıdır.

13 - Ön Kestirim

```
on_kestirim <- data.frame(  
  x1 = 8.2,  
  x3 = 7.5,  
  x4 = factor(1, levels = c(1, 2, 3))  
)  
  
predict(son_model_v2, newdata = on_kestirim)  
  
##          1  
## 89.94237
```

Tahmin edilen $\tilde{y} = 89.94237$

Yorum: Yapılan analiz sonucunda, belirlenen bu yeni koşullar altında 1. çimento türü (Portland) referans grup olarak alınıp diğer türler 0 değeri alınca çimento sağlamlığının 89.94237 mpa olacağı tahmin edilmektedir.

14 - Uyum Kestirimi ve Ön Kestirime Ait Güven Aralıkları

```
uyum_kestirimi_ga <- son_veri[41, ]
guven_araligi <- predict(son_model_v2, newdata = uyum_kestirimi_ga, interval
= "confidence", level = 0.95)
print(guven_araligi)
```

```
##          fit      lwr      upr
## 43 39.32035 38.9853 39.65541
```

$$P(38.9853 \leq E(\hat{y}) \leq 39.65541) = 0.95$$

Yorum: Veri kümesindeki 43. gözlemle (temizlenmiş veri setindeki 41. satır) aynı özelliklere sahip tüm örneklerin ortalama çimento sağlamlığının %95 güvenle 38.9853 ile 39.65541 birimleri arasında olması beklenmektedir.

```
on_kestirim_ga <- data.frame(
  x1 = 8.2,
  x3 = 7.5,
  x4 = factor(1, levels = c(1, 2, 3))
)
ongoru_araligi <- predict(son_model_v2, newdata = on_kestirim_ga, interval =
"prediction", level = 0.95)
print(ongoru_araligi)
```

```
##          fit      lwr      upr
## 1 89.94237 87.59953 92.28521
```

$$P(87.59953 \leq E(\tilde{y}) \leq 92.28521) = 0.95$$

Yorum: Belirlenen yeni koşullara sahip (x1=8.2, x3=7.5, Tür 1) tek bir yeni gözlemin çimento sağlamlığının %95 güvenle 87.59953 ile 92.28521 birimleri arasında olacağı öngörülmektedir.

15 - Değişken Seçimi ile Model Kurma

1 - İleriye Doğru Seçim Yöntemi

```
lm.null <- lm(y ~ 1)

forward <- step(lm.null, y ~ x1 + x2 + x3 + factor(x4), direction = "forward"
)

## Start:  AIC=947.4
## y ~ 1
##
##           Df Sum of Sq    RSS    AIC
## + x1       1  18079.7  6301.3  684.20
## + x2       1   7979.3 16401.8  871.70
## + factor(x4) 2   3580.7 20800.4  920.26
## + x3       1   1829.8 22551.3  934.10
## <none>                        24381.1  947.40
##
## Step:  AIC=684.2
## y ~ x1
##
##           Df Sum of Sq    RSS    AIC
## + factor(x4) 2    5648.8   652.5  243.73
## + x3         1     559.9  5741.4  667.96
## <none>                        6301.3  684.20
## + x2         1         0.8  6300.5  686.17
##
## Step:  AIC=243.73
## y ~ x1 + factor(x4)
##
##           Df Sum of Sq    RSS    AIC
## + x3         1    412.17  240.35  49.978
## <none>                        652.52  243.734
## + x2         1      3.79  648.72  244.591
##
## Step:  AIC=49.98
## y ~ x1 + factor(x4) + x3
##
##           Df Sum of Sq    RSS    AIC
## + x2         1     232.1    8.242 -609.09
## <none>                        240.347   49.98
##
## Step:  AIC=-609.09
## y ~ x1 + factor(x4) + x3 + x2

forward

##
## Call:
```

```
## lm(formula = y ~ x1 + factor(x4) + x3 + x2)
##
## Coefficients:
## (Intercept)          x1  factor(x4)2  factor(x4)3          x3
x2
##      10.633      10.282      -11.998      -11.960      -2.384      1.6
97
```

Yorum: Bağımlı değişken y olduğu durumda birinci adımda modele x1 değişkeni girmiştir. Daha sonra x4, x3 ve son olarak bu veri setinde anlamlı olan x2 değişkeni de modele eklenmiştir. Tüm değişkenler modele dahil edilmiştir.

summary(forward)

```
##
## Call:
## lm(formula = y ~ x1 + factor(x4) + x3 + x2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.21378 -0.14149 -0.08738  0.06790  0.75559
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.63251    0.09141  116.32  <2e-16 ***
## x1           10.28197    0.02028   507.11  <2e-16 ***
## factor(x4)2 -11.99832    0.03792  -316.44  <2e-16 ***
## factor(x4)3 -11.96017    0.03780  -316.37  <2e-16 ***
## x3           -2.38446    0.01962  -121.51  <2e-16 ***
## x2           1.69671    0.02320    73.15  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2083 on 190 degrees of freedom
## Multiple R-squared:  0.9997, Adjusted R-squared:  0.9997
## F-statistic: 1.124e+05 on 5 and 190 DF,  p-value: < 2.2e-16
```

Yorum:

$$\begin{aligned} & \text{En iyi model: } \hat{y} \\ & = 10.6325 + 10.2820X_1 + 1.6967X_2 - 2.3845X_3 - 11.9983D_2 - 11.9602D_3 \\ & \quad \begin{matrix} (0.0914) & (0.0203) & (0.0232) & (0.0196) & (0.0379) & (0.0378) \end{matrix} \\ & \pm 0.2083 \end{aligned}$$

p değerlerinden görüldüğü üzere modeldeki bağımsız değişkenler %95 güven düzeyinde anlamlıdır ($p < 2.2e-16$). Modelin de anlamlı olduğu görülmektedir ($p < 2.2e-16$).

2 - Geriye Doğru Seçim Yöntemi

```
full_model <- lm(y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
```

```
backward <- step(full_model, direction = "backward")
```

```
## Start: AIC=-609.09
## y ~ x1 + x2 + x3 + factor(x4)
##
##           Df Sum of Sq    RSS    AIC
## <none>          8.2 -609.09
## - x2           1    232.1   240.3   49.98
## - x3           1    640.5   648.7  244.59
## - factor(x4)    2   5533.3  5541.5  663.01
## - x1           1  11155.8 11164.0  802.30
```

Yorum: Geriye doğru seçim yönteminin özelliğinden tüm değişkenler modelde olarak başlıyor. Bu yeni veri setinde hiçbir değişken modelden elenmemiştir, çünkü hepsi anlamlıdır ($p < 0.05$).

```
summary(backward)
```

```
##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.21378 -0.14149 -0.08738  0.06790  0.75559
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.63251    0.09141  116.32  <2e-16 ***
## x1           10.28197    0.02028   507.11  <2e-16 ***
## x2            1.69671    0.02320    73.15  <2e-16 ***
## x3           -2.38446    0.01962  -121.51  <2e-16 ***
## factor(x4)2  -11.99832    0.03792  -316.44  <2e-16 ***
## factor(x4)3  -11.96017    0.03780  -316.37  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2083 on 190 degrees of freedom
## Multiple R-squared:  0.9997, Adjusted R-squared:  0.9997
## F-statistic: 1.124e+05 on 5 and 190 DF, p-value: < 2.2e-16
```

Yorum: Aynı bağımsız değişkenler ile model kurulduğundan ileri ve geriye doğru seçim yöntemleri aynı sonuçları vermiştir. Burada da tüm değişkenlerin modelde kaldığı görülmektedir. Modelin anlamlı olduğu söylenebilir ($p < 2.2e-16$). Modele giren tüm değişkenlerin de anlamlı olduğunu söyleyebiliriz ($p < 2.2e-16$).

3 - Adımsal Seçim Yöntemi


```
step.model <- stepAIC(full_model, direction = "both" , trace="FALSE")
summary(step.model)

##
## Call:
## lm(formula = y ~ x1 + x2 + x3 + factor(x4), data = son_veri)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.21378 -0.14149 -0.08738  0.06790  0.75559
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.63251    0.09141  116.32  <2e-16 ***
## x1           10.28197    0.02028   507.11  <2e-16 ***
## x2            1.69671    0.02320    73.15  <2e-16 ***
## x3           -2.38446    0.01962  -121.51  <2e-16 ***
## factor(x4)2  -11.99832    0.03792  -316.44  <2e-16 ***
## factor(x4)3  -11.96017    0.03780  -316.37  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2083 on 190 degrees of freedom
## Multiple R-squared:  0.9997, Adjusted R-squared:  0.9997
## F-statistic: 1.124e+05 on 5 and 190 DF,  p-value: < 2.2e-16
```

Yorum: Yapılan adımsal değişken seçimi yöntemi sonucunda, modele katkısı son derece anlamlı olan tüm bağımsız değişkenler (x1, x2, x3 ve x4) modelde tutulmuştur. Bağımsız değişkendeki değişimin %99.97'si modele giren bağımsız değişkenlerle açıklanabilmektedir.

16 - Ridge Regresyon

```
ridge <- lm.ridge(y ~ x1 + x2 + x3 + factor(x4), data = son_veri, lambda = seq(0, 1000, 50))
matplot(ridge$lambda, t(ridge$coef), type = "l",
        xlab = expression(lambda),
        ylab = expression(hat(beta)))
abline(h=0,lwd=2)
```



```
ridge$coef
```

Yorum: Lamda parametresine göre katsayılar değişmektedir. Hızlı azalış ve artışların bittiği yerde bir lambda parametresi belirlenerek katsayı kestirimleri elde edilir ve model kurulur. Lamdanın 100 olarak alındığı durumun sonuçlarına göre katsayı kestirimleri elde edilmiştir. Lamda 100 civarında alınabilir.

```
ridge$coef[, ridge$lam == 100]
```

```
##          x1          x2          x3 factor(x4)2 factor(x4)3
##  5.7891016  2.0672689 -0.5601972 -2.4139729 -2.5861158
```

Yorum: Hızlı artış ya da azalış gösteren katsayılara karşılık gelen değişkenler çoklu bağlantılı değişkenlerdir. Grafikte katsayıların seyri incelendiğinde, bu yeni veri setinde çok ciddi bir çoklu bağlantı sorunu olmadığı için katsayı değişimleri oldukça yumuşak ve

dengelidir. Tüm deęiřkenler sıfırdan farklı ve anlamlı katsayılara sahip olduęu için ridge izi grafięi de bu deęiřkenlerin modele katkı saęladığını doęrulamaktadır.